Observatoire statistique des parcours et de la réussite universitaire

Rapport final — démonstrateur sur données entièrement fictives

AUTEUR·RICE
Projet de simulation universitaire

DATE DE PUBLICATION
21 octobre 2026

1 Résumé exécutif

Ce projet démontre une chaîne statistique complète : cadrer une commande universitaire, simuler des tables relationnelles, fiabiliser les données, définir les indicateurs, analyser les parcours et enquêtes, puis restituer les résultats dans des tableaux de bord et des rapports reproductibles.

Toutes les données sont entièrement fictives. Aucun chiffre ne représente un résultat réel de l'UPEC. Le contexte UPEC / DEVE / SPOF est une inspiration professionnelle, sans affiliation officielle ni accès aux systèmes internes.

En 2025-2026, le jeu préparé compte **10222 inscrits**, avec **73.2 % de validation annuelle sur les éligibles**. La satisfaction atteint **71.4 % parmi les avis exprimés**, pour une participation de **50.7 %**. Le devenir des diplômés de juillet 2026 n'est pas encore observable à six mois au 30 septembre 2026.

La chaîne comporte 104 assertions R validées, des contrôles de navigation et de filtres pour les interfaces web/Shiny et 126 rapprochements R/DAX historiques réussis dans le moteur de Power BI Desktop. Ces vérifications étayent la fiabilité technique du démonstrateur, sans valider une méthode institutionnelle ni la pertinence de décisions réelles.

2 Contexte et objectifs

La commande simulée vise à aider les responsables de formation et de pilotage à comprendre les inscriptions, la réussite, les réorientations, l'évaluation des formations et le devenir des diplômés. Elle mobilise les compétences d'un chargé d'études : explicitation du besoin, maîtrise des populations, contrôle qualité, analyse et restitution accessible.

La question centrale est : **comment exploiter conjointement scolarité et enquêtes pour comprendre les parcours et éclairer le pilotage de l'offre de formation ?**

Les objectifs opérationnels sont de construire un système de tables cohérent, une production vérifiable, des indicateurs aux dénominateurs explicites et des livrables utilisables sans maîtrise de R. Le démonstrateur comprend une interface web, une application R Shiny, un projet Power BI natif et des rapports Quarto. Il n'a pas pour objectif d'établir un classement réel des formations ni une prédiction individuelle.

3 Données et périmètre

La référence synthétique comprend 15 000 personnes distinctes sur trois années universitaires, de 2023-2024 à 2025-2026, et cinq formations fictives de licence/master. Une seule inscription principale est admise par personne et année. La clôture d'observation est fixée au **30 septembre 2026**.

Table	Unité d'observation	Contenu
etudiants	personne fictive	profil, année de naissance, bac, bourse, entrée observée

Table	Unité d'observation	Contenu
formations	formation fictive	cycle, composante et niveau terminal
inscriptions	inscription principale annuelle	étudiant, formation, niveau, régime
resultats	bilan annuel d'inscription	validation oui/non/inconnue, ECTS, jury
parcours	transition depuis une inscription	passage, redoublement, réorientation, fin diplômée, sortie, inconnu, censure
evaluation	sollicitation d'une inscription	délivrance, réponse, avis et items partiels
diplomes	diplôme obtenu	inscription terminale, type et date
insertion	suivi d'un diplôme à six mois	éligibilité, invitation, réponse et situation

L'étudiant, l'inscription et le diplôme sont des unités distinctes. La cohorte d'entrée observée dans la fenêtre ne se confond pas avec une cohorte nationale de primo-entrants dans l'enseignement supérieur. La première année inclut un stock d'étudiants déjà avancés dans leur cycle.

La simulation intègre des différences artificielles entre formations, des profils incomplets, des résultats inconnus et des réponses partielles. Les trajectoires sont d'abord rendues cohérentes ; les anomalies techniques sont introduites ensuite dans une copie dédiée au contrôle qualité. Les paramètres et la graine sont documentés dans les sources téléchargeables.

4 Qualité et traçabilité

La chaîne conserve trois états distincts : référence synthétique cohérente, copie brute avec anomalies contrôlées, puis tables préparées. Les douze injections incluent huit doublons exacts, un profil contradictoire, des ECTS hors domaine, une référence orpheline et une note hors échelle. Elles ont toutes été repérées par la recette.

Le nettoyage ne lit pas le registre des valeurs de référence pour « deviner » les corrections. Les lignes strictement identiques sont dédupliquées ; les conflits et leurs dépendances sont placés en quarantaine. Les valeurs inconnues plausibles ne sont pas imputées arbitrairement.

	Table	Lignes brutes	Lignes préparées
etudiants	etudiants	15002	14999
formations	formations	6	5
inscriptions	inscriptions	24221	24217
resultats	resultats	24222	24217
parcours	parcours	24221	24217
evaluation	evaluation	24221	24216
diplomes	diplomes	4774	4772
insertion	insertion	4774	4772

Après préparation, **14998 personnes** disposent d'au moins une inscription exploitable, pour 24217 inscriptions annuelles. Le référentiel étudiant peut conserver des personnes dont toutes les inscriptions ont été écartées ; ces unités ne doivent pas être confondues dans un total.

Les contrôles couvrent unicité des clés, références, domaines, chronologie, cohérence ECTS/validation/diplôme et trajectoires. Le journal garde les clés, le contrôle et la décision. Zéro violation bloquante ne signifie pas que toutes les erreurs imaginables sont identifiables à partir des seules données.

5 Méthodes et définitions

Chaque indicateur précise population, unité, numérateur, dénominateur, exclusions et période. Un dénominateur nul produit une valeur non calculable, pas zéro. Les taux agrégés sont recalculés à partir des comptes, jamais par moyenne simple de pourcentages.

Indicateur	Numérateur	Dénominateur / règle
Effectif	étudiants distincts avec inscription principale	année et formation définies
Évolution	effectif courant moins précédent	effectif précédent, années consécutives
Validation annuelle	validations connues oui	toutes les inscriptions éligibles
Passage	réinscription au niveau immédiatement supérieur, même formation	cohorte suivable non terminale
Réorientation	réinscription dans une autre formation	cohorte suivable complète
Participation	répondants à au moins un item substantiel	invitations effectivement délivrées
Satisfaction	notes 4 ou 5 à l'item global	avis valides 1 à 5, hors sans avis et items vides
Emploi à six mois	répondants éligibles en emploi	répondants éligibles de situation connue, études comprises

La validation annuelle ne désigne pas la diplomation terminale. Les résultats inconnus restent au dénominateur du taux sur éligibles sans être qualifiés individuellement d'échecs. Le taux parmi connus et la couverture sont donc présentés ensemble.

Pour la diffusion, les petits comptes positifs et compléments de 1 à 4 sont protégés. Le paquet de tableaux de bord applique une règle conservatrice : masquer toute une famille de comptes pour toutes les formations d'une année si une cellule est sensible. Aucun identifiant individuel ni compte masqué n'est transmis au navigateur. Ce seuil est une convention pédagogique, pas une norme institutionnelle.

6 Enquêtes et devenir des diplômés

Le protocole d'évaluation définit population invitée, participation volontaire, modalités 1–5, sans avis, réponses partielles et clôture. Les questionnaires fournis sont des matrices de transposition vers LimeSurvey, sans import natif testé ni envoi réel.

Année	Sollicités	Répondants	Avis	Satisfaits	Sans avis	Items vides	Participation	Satisfaction
2023-2024	5756	2967	2482	1755	132	353	51.5 %	70.7 %
2024-2025	7704	3936	3269	2312	192	475	51.1 %	70.7 %
2025-2026	9805	4967	4120	2942	255	592	50.7 %	71.4 %

La satisfaction décrit les répondants ayant exprimé un avis valide. La non-réponse et les écarts de participation par profil peuvent entraîner des biais ; aucun redressement ou extrapolation implicite n'est appliqué. Les identifiants sont fictifs mais permettent une jointure par profil : le scénario lié ne doit pas être qualifié d'anonyme au sens d'une collecte réelle.

Année diplôme	Diplômés	Éligibles	Non matures	Sollicités	Répondants	Connus	Emploi	Actifs	Emploi / connus	Insertion / actifs
2023-2024	1747	1747	0	1648	1011	983	576	714	58.6 %	80.7 %
2024-2025	1437	1437	0	1353	844	821	500	612	60.9 %	81.7 %

Année diplôme	Diplômes	Éligibles	Non matures	Sollicités	Répondants	Connus	Emploi	Actifs	Emploi / connus	Insertion / actifs
2025-2026	1588	0	1588	0	0	0	0	0	Non observable	Non observable

Le suivi d'insertion utilise six mois **calendaires** après le diplôme. Les 1588 diplômés non encore matures ne sont ni des non-répondants ni des personnes sans emploi. Emploi parmi situations connues et insertion parmi actifs ont des dénominateurs différents. Les totaux annuels de cette étude ne constituent pas les détails par formation du paquet Power BI, où de petits comptes sont supprimés.

7 Parcours et suivi longitudinal

Les transitions sont construites après rapprochement des inscriptions de deux années consécutives. Le classement distingue autre formation, passage dans la même formation, redoublement, fin de formation diplômée, sortie explicitement documentée et situation inconnue. Les transitions de la dernière année sont censurées.

Année départ	Suivis	Passages	Redoubl.	Réorient.	Sorties observées	Inconnus	Fins diplômées	Censurés
2023-2024	5969	2429	988	142	272	391	1747	0
2024-2025	8026	4067	1400	193	382	547	1437	0
2025-2026	0	0	0	0	0	0	0	10222

Une absence de réinscription ne prouve pas un abandon définitif. Une sortie observée exige une information explicite et datée. Une fin de cycle diplômée ne prouve pas non plus la sortie de tout l'enseignement supérieur. Le passage exclut les niveaux terminaux, contrairement au dénominateur général de réorientation.

Les cohortes de départ 2023-2024 et 2024-2025 sont suivables dans cette fenêtre. La cohorte 2025-2026 ne peut être observée en 2026-2027 à la clôture. Une comparaison longitudinale doit donc considérer simultanément la durée de suivi disponible, les niveaux et la composition des cohortes.

8 Modélisation exploratoire

Le modèle logistique retient la première inscription exploitable chronologique de chaque étudiant et un résultat connu. Le modèle principal utilise des profils bac/bourse complets. Les prédicteurs sont disponibles avant jury : formation, niveau, âge, bac, bourse et année. ECTS, diplôme, résultat du jury, transition future et identifiant sont exclus pour éviter les fuites de cible.

Une seule observation par personne évite la dépendance des inscriptions répétées dans cet exercice initial. Le découpage reproductible 70/30 sépare les étudiants entre apprentissage et évaluation ; il ne mesure pas une prédiction temporelle sur une année future.

	indicateur	valeur
n_premieres_inscriptions	n_premieres_inscriptions	14998
n_inclus	n_inclus	13473
n_exclus_resultat	n_exclus_resultat	388
n_exclus_profil_parmi_resultats_connus	n_exclus_profil_parmi_resultats_connus	1137
n_train	n_train	9431
n_test	n_test	4042

	indicateur	valeur
etudiants_communs	etudiants_communs	0
convergence	convergence	1
evenements_par_parametre	evenements_par_parametre	207
probabilite_min	probabilite_min	0.479
probabilite_max	probabilite_max	0.851
vif_max	vif_max	2.073
brier	brier	0.189
auc	auc	0.607
calibration_intercept	calibration_intercept	-0.031
calibration_pente	calibration_pente	1.013

	terme	coefficient	erreur_standard	odds_ratio	borne_basse	borne_haute
(Intercept)	(Intercept)	0.471	0.333	1.602	0.834	3.078
formation_idF02	formation_idF02	0.427	0.066	1.533	1.347	1.745
formation_idF03	formation_idF03	0.248	0.066	1.282	1.127	1.458
formation_idF04	formation_idF04	0.690	0.097	1.993	1.650	2.409
formation_idF05	formation_idF05	0.581	0.098	1.787	1.476	2.164
niveau	niveau	0.217	0.053	1.242	1.120	1.378
age	age	0.005	0.018	1.005	0.971	1.041
type_bacprofessionnel	type_bacprofessionnel	-0.731	0.086	0.481	0.407	0.569
type_bactechnologique	type_bactechnologique	-0.504	0.056	0.604	0.542	0.674
boursier	boursier	-0.140	0.049	0.869	0.789	0.957
annee2024-2025	annee2024-2025	0.016	0.070	1.016	0.885	1.166
annee2025-2026	annee2025-2026	0.186	0.071	1.204	1.048	1.384

L'AUC d'environ **0.607** indique une discrimination limitée. La convergence ne suffit donc pas à justifier un usage individuel. Les diagnostics contrôlent rang, erreurs standards, coefficients extrêmes, événements par paramètre, VIF, Brier et calibration. Les intervalles de Wald à 95 % reposent sur les hypothèses du modèle.

bin	n	prediction	observe
1	404	0.585	0.574
2	404	0.660	0.619
3	404	0.693	0.673
4	404	0.719	0.728
5	405	0.739	0.783
6	404	0.760	0.790
7	404	0.777	0.767
8	404	0.798	0.795
9	404	0.815	0.824
10	405	0.836	0.795

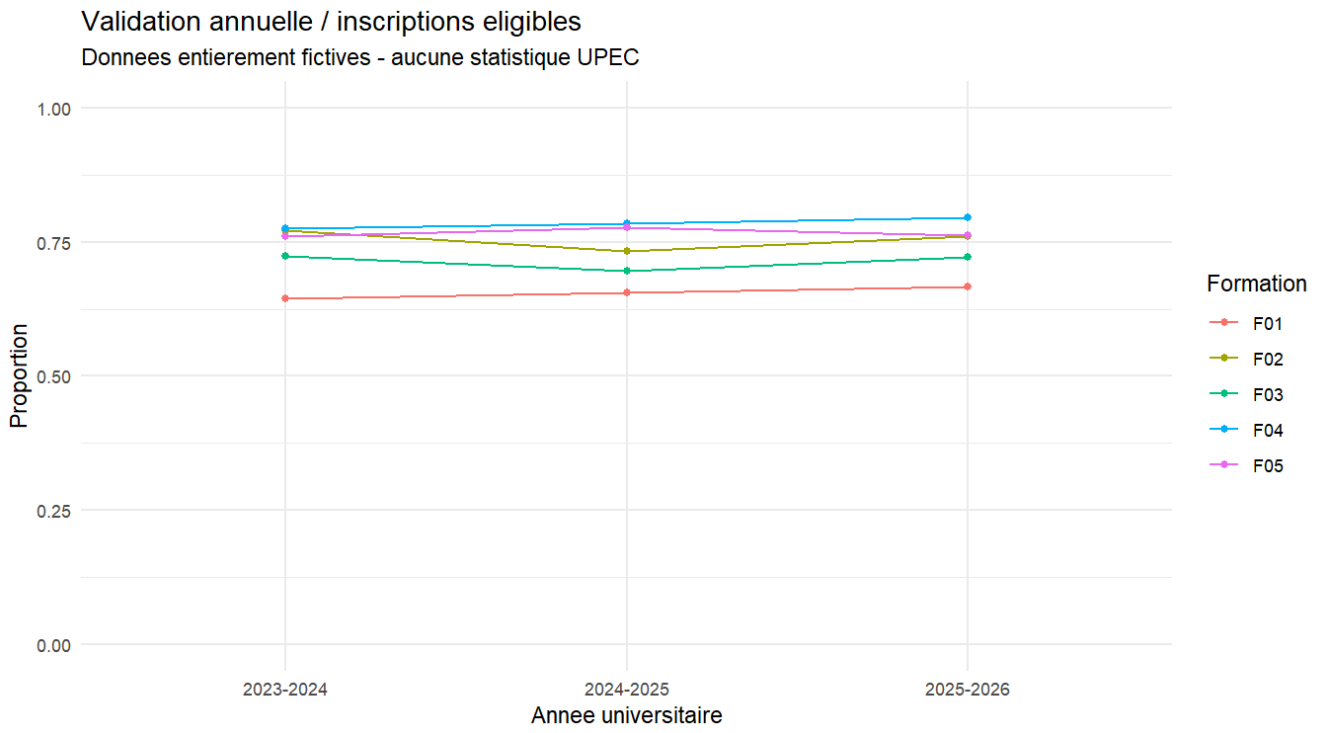
	formation_id	niveau	age	type_bac	boursier	annee	probabilite
11222	F05	1	21	general	0	2023-2024	0.800
7052	F04	1	21	general	0	2023-2024	0.817
5504	F02	1	21	general	0	2023-2024	0.774
3302	F03	1	21	general	0	2023-2024	0.741
13888	F01	1	21	general	0	2023-2024	0.691

Les probabilités standardisées fixent l'âge à 21 ans, le premier niveau, un bac général, l'absence de bourse et l'année initiale. Elles illustrent le modèle et ne représentent pas une moyenne réelle de formation. Une sensibilité traite les profils manquants comme catégories explicites ; elle ne constitue pas une imputation ni une preuve d'absence de biais.

9 Résultats descriptifs

Année	Inscrits	Validés	Connus	Inconnus	Diplômés	Élig. diplôme	Validation / tous	Couverture	Validation / connus
2023-2024	5969	4338	5823	146	1747	2289	72.7 %	97.6 %	74.5 %
2024-2025	8026	5745	7821	205	1437	1858	71.6 %	97.4 %	73.5 %
2025-2026	10222	7478	9934	288	1588	2045	73.2 %	97.2 %	75.3 %

En 2025-2026, 7478 validations sont connues parmi 10222 inscriptions éligibles. Avec 288 résultats inconnus, la validation sur l'ensemble des éligibles se situe entre **73.2 % et 76.0 %**, selon les résultats hypothétiques des absents. Aucun de ces résultats n'est imputé individuellement.



La progression des effectifs résulte de l'accumulation des cohortes et des probabilités artificielles de maintien. Elle ne mesure pas l'attractivité d'une université. Les différences de validation combinent paramètres du simulateur et composition des populations ; aucune hiérarchie de qualité des formations n'en découle.

10 Indicateurs décisionnels

Question de pilotage	Indicateur à lire	Information complémentaire indispensable
Combien d'inscrits accueille-t-on ?	effectifs distincts par année et formation	périmètre et évolution comparable
Quel niveau de validation observe-t-on ?	validation sur éligibles	couverture, taux parmi connus et bornes
Quels parcours sont suivis ?	passage et réorientation	terminales, inconnus et censure
Que disent les répondants ?	satisfaction	participation, sans avis et non-réponse
Quel devenir après diplôme ?	emploi et insertion parmi actifs	horizon, éligibilité et situations connues

Le site donne accès à trois modalités de restitution. Le tableau de bord **web** fonctionne dans le navigateur à partir des agrégats protégés. **Shiny** propose les mêmes vues avec des réactifs R ; sa source est disponible et nécessite un serveur R local ou un hébergement adapté. **Power BI** fournit un projet natif PBIP de trois pages, avec filtres année/formation, quatre cartes et évolution de la validation.

Le modèle Power BI, ses sept tables, six relations et 35 mesures ont été chargés dans Desktop. L'actualisation et 126 rapprochements R/DAX sont réussis. La validation du moteur ne se confond pas avec une inspection exhaustive du canvas natif. Aucun service Power BI, hébergement Shiny distant ou rafraîchissement distant n'est actif.

11 Recommandations de pilotage

Les recommandations suivantes illustrent une méthode de travail, sans prescrire d'action pour une formation réelle à partir de chiffres fictifs.

1. **Sécuriser les définitions avant comparaison.** Valider les populations, les fenêtres et les exclusions avec le commanditaire ; conserver un dictionnaire versionné.
2. **Qualifier les situations inconnues.** Organiser un suivi explicite plutôt qu'un recodage automatique d'absence de réinscription en abandon.
3. **Accompagner les taux de leur couverture.** Présenter les comptes, les résultats manquants et les bornes de sensibilité pour éviter une lecture trompeuse de la réussite.
4. **Examiner la non-réponse.** Comparer participation et profils avant d'utiliser la satisfaction comme élément d'arbitrage ; ne pas confondre sans avis et avis défavorable.
5. **Industrialiser une production contrôlée.** Séparer données sources, corrections, indicateurs et diffusion ; tester les filtres et les règles de masquage après actualisation.

Contribution illustrative à l'autoévaluation	Preuve du démonstrateur	Précaution
Connaissance des publics	profils, effectifs et évolutions	périmètre à convenir
Suivi des parcours	validation, transitions et censure	devenir incomplet
Écoute des étudiants	questionnaire et analyse des avis	non-réponse et biais
Devenir des diplômés	horizon de six mois documenté	maturité et situation connue
Fiabilité de la production	journal, versions et tests	contrôles non exhaustifs

Cette matrice ne revendique aucune conformité à un référentiel HCERES ni validation institutionnelle.

12 Limites et précautions

- **Simulation intégrale.** Les écarts et les associations proviennent d'un mécanisme artificiel ; ils n'étayent aucune conclusion sur l'UPEC.

- **Fenêtre courte.** Trois années ne permettent pas de suivre tous les cycles jusqu'au diplôme ni les transitions de la dernière année.
- **Mécanismes simplifiés.** Pas de pause suivie de retour après sortie, une seule inscription principale et absence de retour après diplôme dans ce scénario.
- **Manques et sélection.** Profils incomplets, résultats inconnus et non-réponse peuvent modifier les populations analytiques ; aucune correction universelle n'est revendiquée.
- **Modèle exploratoire.** AUC limitée, hypothèses de modélisation, absence de causalité et aucune utilisation pour une décision individuelle.
- **Diffusion.** Le seuil de masquage est une convention pédagogique. Une collecte réelle exige un cadrage, des droits d'accès et des règles de confidentialité adaptés.
- **Outils et déploiements.** L'import LimeSurvey n'est pas testé. Le projet Power BI est livré en PBIP ; aucun PBIX ou déploiement dans le service n'est annoncé. Shiny est une application locale à démarrer. Le site présente fidèlement ces modalités sans les faire passer pour des applications distantes actives.

13 Reproductibilité et accès aux livrables

R, `renv`, `targets`, `testthat` et Quarto organisent la chaîne. La graine, la fenêtre et les probabilités figurent dans la configuration. La même graine reproduit des objets identiques à versions R et dépendances constantes. La reprise sans changement et l'invalidation après modification/restauration de graine ont été vérifiées.

```
# À la racine du projet après restauration de renv.lock
renv::restore()
source("scripts/run_pipeline.R")
source("scripts/run_tests.R")
# Dans un terminal à la racine : quarto render
# Application R : source("scripts/run_shiny.R")
```

Les sources Quarto produisent les chiffres depuis les sorties R, sans remplacement manuel par les valeurs de la maquette initiale. Le site est un instantané : une nouvelle production doit être rendue, contrôlée puis republiée. La CI est préparée localement mais n'a pas été exécutée sur GitHub pendant la réalisation.

Les accès principaux sont réunis sur le site de présentation :

- Tableau de bord web interactif.
- Rapport final en PDF et source Quarto.
- Note de pilotage de deux pages et PDF.
- Rapport d'enquêtes et présentation de dix minutes.
- Projet Power BI natif et agrégats protégés.
- Application R Shiny et archive reproductible du projet.

Les archives de présentation excluent identifiants individuels, données brutes, bibliothèques locales, caches, journaux contenant des chemins utilisateurs et secrets. Seuls les agrégats protégés sélectionnés sont diffusés. Ces liens sont prévus pour la version publiée ; les fichiers locaux restent organisés dans le dépôt du projet.